

UNIVERSITATEA „LUCIAN BLAGA” DIN SIBIU
FACULTATEA DE ȘTIINȚE

PROIECT DE PRACTICĂ

Chatbot pentru Sănătatea Mintală

MindCare Enterprise AI - Arhitectură Full-Stack

Autor:

Stoica Alexandru

Sibiu

2026

Cuprins

1	Introducere și Motivație	3
1.1	Contextul Global și Necesitatea Proiectului	3
1.2	Obiectivele Proiectului de Practică	3
1.3	Structura Lucrării	4
2	Stadiul Actual al Cunoașterii	5
2.1	Evoluția Chatboților în Psihologie	5
2.2	Revoluția Modelelor Transformer și LLM	5
2.3	Limitările Abordărilor Curente în Sănătate	6
3	Fundamente Teoretice și Algoritmice	7
3.1	Vectorizarea Textului: Modelul TF-IDF	7
3.2	Rețeaua Neuronală Artificială (MLP)	8
3.3	Retrieval-Augmented Generation (RAG) și Căutarea Semantică	9
4	Arhitectura și Tehnologii Utilizate	10
4.1	Ecosistemul și Mediul de Dezvoltare	10
4.2	Componentele Arhitecturii Multi-Agent	10
4.3	Securitatea Datelor și Criptarea Locală	11
5	Implementarea Sistemului MindCare	12
5.1	Autentificarea și Securitatea	12
5.2	Autentificarea și Securitatea	12
5.3	Interfața Principală de Chat	13
5.4	Profilul Utilizatorului și Monitorizarea	13
5.5	Jurnalul Zilnic (Mood Journal)	14
5.6	Modulul de Relaxare (Intervenție Fiziologică)	15
5.7	Baza de Date Dinamică (Import RAG)	16
5.8	Sistemul de Telemetrie și Dashboard	16
5.9	Exportul Datelor și a Rapoartelor	17
5.10	Diagnosticare și Evaluarea Machine Learning	18

6	Testare, Validare și Performanță	19
6.1	Evaluarea Modelului de Machine Learning	19
6.2	Validarea Interogărilor RAG (Prevenția Halucinațiilor)	20
6.3	Testarea Interfeței Asincrone (Multithreading)	20
7	Concluzii și Direcții Viitoare de Cercetare	21
7.1	Concluzii Generale	21
7.2	Direcții de Dezvoltare Viitoare	21
8	Bibliografie	23

1 Introducere și Motivație

1.1 Contextul Global și Necesitatea Proiectului

În deceniul actual, marcat de o digitalizare accelerată și de schimbări socio-economice profunde, sănătatea mintală a devenit una dintre cele mai presante provocări la nivel global. Conform rapoartelor recente ale Organizației Mondiale a Sănătății (OMS), prevalența afecțiunilor precum anxietatea și depresia a crescut alarmant, afectând sute de milioane de persoane. Stresul cronic și sindromul de burnout sunt omniprezente, în special în rândul tinerilor adulți, al studenților și al angajaților din mediul corporativ. Ritmul de viață alert și presiunea constantă a mediului digital contribuie semnificativ la deteriorarea echilibrului psiho-emoțional.

În ciuda acestei „pandemii tăcute”, sistemele tradiționale de asistență psihologică sunt adesea ineficiente în a oferi suport imediat și scalabil. Accesul la un specialist este frecvent îngreunat de costurile ridicate ale ședințelor de terapie, de lipsa de timp, de listele de așteptare lungi, dar și de un puternic stigmat social care încă persistă în multe culturi. Există, așadar, o nevoie imperativă pentru metode alternative de prim ajutor emoțional, care să fie accesibile, anonime și disponibile în orice moment.

Inteligența Artificială (IA) și Procesarea Limbajului Natural (NLP) au evoluat suficient pentru a suplini o parte din această nevoie. Asistenții virtuali conversaționali (chatbotii) nu obosesc, nu judecă, nu manifestă bias-uri emoționale umane și pot oferi suport psihologic de bază la orice oră din zi sau din noapte.

1.2 Obiectivele Proiectului de Practică

Acest proiect de practică a avut ca scop principal proiectarea, dezvoltarea și validarea unui sistem software complex, denumit **MindCare Enterprise AI**. Această aplicație reprezintă un asistent virtual full-stack capabil să interacționeze natural cu utilizatorii, să le analizeze starea emoțională utilizând modele predictive și să ofere suport informațional validat științific, alături de tehnici de relaxare imediată.

Obiectivele tehnice și de cercetare ale acestui proiect includ:

1. **Dezvoltarea unei Interfețe Grafice (GUI):** Construirea unui mediu de interacțiune

prietenos și responsiv, folosind framework-ul **Tkinter**, care să redea o experiență de utilizare de tip desktop nativ.

2. **Implementarea unui Modul de Analiză Emoțională (ML):** Antrenarea unui clasificator bazat pe Rețele Neuronale (Multi-Layer Perceptron) folosind biblioteca **Scikit-Learn** pentru a diferenția stările de stres și depresie din input-ul de text.
3. **Integrarea Modelelor Generative (LLM):** Utilizarea tehnologiei dezvoltate de OpenAI (prin API RESTful) și a framework-ului **LangChain** pentru a genera răspunsuri contextuale, empatică și fluide.
4. **Prevenirea Halucinațiilor IA (RAG):** Construirea unei baze vectoriale proprii (FAISS) pentru a asigura fundamentarea sfaturilor oferite pe date medicale și psihologice valide, eliminând riscul generării de informații medicale false.
5. **Implementarea Funcționalităților Auxiliare:** Dezvoltarea unui sistem de gestiune a utilizatorilor (securitate și criptare), crearea unui jurnal zilnic inteligent (Mood Journal), integrarea exercițiilor de respirație ghidată și exportul rapoartelor de telemetrie și conversație în format PDF.

1.3 Structura Lucrării

Prezenta lucrare este structurată în opt capitole. **Capitolul 2** prezintă stadiul actual al cunoașterii în domeniul asistenților medicali virtuali. **Capitolul 3** descrie fundamentele teoretice și matematice ale algoritmilor folosiți (TF-IDF, MLP, RAG). **Capitolul 4** detaliază arhitectura de ansamblu și tehnologiile alese. **Capitolul 5** ilustrează implementarea practică și interfața grafică a sistemului. **Capitolul 6** abordează metodologia de testare și validare, **Capitolul 7** rezumă concluziile și direcțiile viitoare, iar **Capitolul 8** conține referințele bibliografice.

2 Stadiul Actual al Cunoașterii

2.1 Evoluția Chatboților în Psihologie

Conceptul de a folosi o mașină pentru a simula un terapeut are rădăcini istorice adânci în informatică. În anul 1966, cercetătorul Joseph Weizenbaum de la MIT a creat **ELIZA**, un program de calculator capabil să emuleze un psihoterapeut rogerian. ELIZA funcționa exclusiv pe baza unor reguli stricte de recunoaștere a tiparelor (pattern matching) și pe reformularea afirmațiilor utilizatorului sub formă de întrebare. Cu toate că nu avea nicio înțelegere reală a limbajului, efectul psihologic asupra utilizatorilor a fost profund. Oamenii tindeau să atribuie inteligență și empatie programului, fenomen cunoscut ulterior în literatura de specialitate ca „Efectul ELIZA”.

La scurt timp, în 1972, psihiatrul Kenneth Colby a creat **PARRY**, un sistem conceput să simuleze un pacient cu schizofrenie paranoică. Testele efectuate au arătat că psihiaștrii umani cu greu puteau distinge transcrierile conversațiilor lui PARRY de cele ale unor pacienți reali, punând astfel bazele testului Turing aplicat în psihiatrie.

În ultimele două decenii, dezvoltarea capacităților de calcul și a algoritmilor de *Deep Learning* a transformat radical acest peisaj. Astăzi, aplicații comerciale precum *Woebot* sau *Wysa* utilizează o combinație de arbori de decizie bazați pe Terapia Cognitiv-Comportamentală (CBT) și module limitate de NLP pentru a ajuta utilizatorii să își gestioneze anxietatea cotidiană.

2.2 Revoluția Modelelor Transformer și LLM

Anul 2017 a marcat un punct de cotitură în inteligența artificială odată cu publicarea lucrării „Attention Is All You Need”, care a introdus arhitectura *Transformer*. Spre deosebire de rețelele recurente (RNN sau LSTM) care procesau textul secvențial, transformatorii procesează întregul context simultan, utilizând mecanismul de atenție (Self-Attention). Această inovație a condus la dezvoltarea modelelor de limbaj de mari dimensiuni (Large Language Models - LLM), precum familia GPT (Generative Pre-trained Transformer) de la OpenAI. Aceste modele pot înțelege nuanțele limbajului, umorul, ironia și pot genera răspunsuri cu o fluentă remarcabilă, deschizând noi orizonturi pentru chatboții de suport

emoțional.

2.3 Limitările Abordărilor Curente în Sănătate

În prezent, majoritatea chatboților destinați sănătății mintale se împart în două categorii, ambele prezentând deficiențe notabile:

- **Chatboți bazați pe reguli (Rule-based):** Sunt siguri din punct de vedere medical, deoarece răspunsurile sunt pre-scrise de specialiști umani. Totuși, aceștia sunt extrem de rigizi. Utilizatorii își pierd repede interesul din cauza fluxului nenatural, repetitiv și mecanic al conversației.
- **Chatboți bazați pe Modele Generative Pure (LLM):** Modele precum ChatGPT pot purta conversații excepționale, pline de empatie simulată, dar prezintă riscul major al „halucinațiilor”. O halucinație apare atunci când modelul generează informații false, dar formulate extrem de plauzibil și convingător. În domeniul sănătății mintale, generarea unui sfat terapeutic inventat sau incorect din punct de vedere medical poate avea consecințe dezastruoase, punând în pericol siguranța pacientului.

Sistemul **MindCare Enterprise AI** propus în acest proiect abordează ambele limitări printr-o arhitectură inovatoare hibridă. Utilizează forța și fluenta LLM-urilor pentru interacțiunea naturală, dar aplică tehnica *Retrieval-Augmented Generation (RAG)* pentru a constrânge modelul să răspundă strict pe baza unui corpus validat de specialiști, eliminând creativitatea periculoasă în domeniul clinic.

3 Fundamente Teoretice și Algoritmice

Dezvoltarea sistemului MindCare implică înțelegerea și aplicarea mai multor concepte avansate de matematică, algebră liniară, statistică și procesare a limbajului natural (NLP).

3.1 Vectorizarea Textului: Modelul TF-IDF

Pentru ca un algoritm de Machine Learning să poată analiza un text (de exemplu, un mesaj al utilizatorului referitor la starea sa), cuvintele (string-urile) trebuie transformate în reprezentări matematice. În modulul de fallback și detecție rapidă s-a utilizat metoda **TF-IDF** (Term Frequency - Inverse Document Frequency).

TF-IDF este o măsură statistică ce evaluează importanța unui cuvânt într-un document, relativ la un corpus întreg de documente. *Term Frequency* (Frecvența Termenului) măsoară de câte ori apare un cuvânt și se calculează astfel:

$$TF(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (1)$$

unde $f_{t,d}$ este numărul de apariții ale termenului t în documentul d .

Inverse Document Frequency (Frecvența Inversă a Documentului) penalizează cuvintele care apar prea des în toate documentele (cum ar fi conjuncțiile "și", "dar", "sau"), deoarece acestea nu oferă informație relevantă despre sentimentul propoziției:

$$IDF(t, D) = \log \frac{N}{|\{d \in D : t \in d\}|} \quad (2)$$

unde N este numărul total de documente din dataset, iar numitorul reprezintă numărul de documente care conțin termenul t . Scorul final ponderat este produsul celor două:

$$TF-IDF(t, d, D) = TF(t, d) \cdot IDF(t, D) \quad (3)$$

Astfel, cuvinte cheie precum „plâng”, „epuizat”, „obosit” vor primi o pondere matematică ridicată, semnalând rețelei o potențială stare de depresie sau burnout.

3.2 Rețeaua Neuronală Artificială (MLP)

Multi-Layer Perceptron (MLP) este o clasă fundamentală de rețea neuronală artificială de tip *feedforward*. Aceasta constă din cel puțin trei straturi de noduri (neuroni artificiali): un strat de intrare, unul sau mai multe straturi ascunse și un strat de ieșire.

În cadrul aplicației MindCare, MLP-ul preia vectorii rezultați din transformarea TF-IDF și calculează o distribuție de probabilitate pentru trei clase țintă: Stres, Depresie sau Normal. Matematica din spatele unui singur neuron de pe stratul ascuns este dată de transformarea afină urmată de o activare non-liniară:

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right) \quad (4)$$

unde w_i reprezintă ponderile sinaptice (weights), x_i sunt semnalele de intrare, b este pragul (bias), iar f este funcția de activare. În acest proiect s-a utilizat funcția de activare **ReLU** (Rectified Linear Unit), definită simplu ca:

$$f(x) = \max(0, x) \quad (5)$$

ReLU a fost preferată deoarece accelerează procesul de calcul și previne problema dispariției gradientului (vanishing gradient problem) în timpul antrenării prin algoritmul de Back-propagation.

Pentru stratul de ieșire, deoarece avem o problemă de clasificare multi-clasă, se folosește funcția *Softmax*, care transformă ieșirile brute (logits) în probabilități valide (care însumate dau 1):

$$\sigma(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (6)$$

Antrenarea rețelei se realizează prin minimizarea funcției de cost *Cross-Entropy* folosind optimizatorul Adam.

3.3 Retrieval-Augmented Generation (RAG) și Căutarea Semantică

RAG este o tehnică hibridă prin care capacitățile de generare ale unui LLM sunt augmentate folosind un mecanism de extragere a informațiilor din baze de date externe, dinamice. Procesul matematic și logic este următorul:

1. **Indexarea:** Documentele sursă de specialitate sunt împărțite în segmente. Fiecare segment este trecut printr-un model de încorporare (Embedding Model - ex. *all-MiniLM-L6-v2*), care proiectează textul într-un spațiu latent n -dimensional (un vector dens de numere reale).
2. **Interogarea:** Când utilizatorul formulează o întrebare, textul acesteia este proiectat în același spațiu latent, rezultând vectorul Q .
3. **Căutarea Similarității:** Baza de date FAISS calculează distanța dintre vectorul întrebării Q și toți vectorii documentelor D_i . Metrica principală este Similaritatea Cosinusului, care măsoară unghiul dintre cei doi vectori:

$$\text{Similarity}(Q, D) = \cos(\theta) = \frac{Q \cdot D}{\|Q\| \|D\|} \quad (7)$$

O valoare apropiată de 1 indică o similaritate semantică ridicată (chiar dacă nu se folosesc aceleași cuvinte exacte).

4. **Generarea:** Cele mai similare 2-3 paragrafe sunt extrase și adăugate ca un „context de fapte” în prompt-ul ascuns trimis către modelul OpenAI, care va sintetiza un răspuns bazat *doar* pe acel context.

4 Arhitectura și Tehnologii Utilizate

Sistemul **MindCare** a fost arhitecturat pentru a fi robust, securizat și rapid, funcționând pe un model de straturi decuplate, apropiat de modelul clasic *Model-View-Controller* (*MVC*).

4.1 Ecosistemul și Mediul de Dezvoltare

Proiectul a fost dezvoltat integral în limbajul **Python**, recunoscut în prezent drept standardul absolut al industriei pentru dezvoltarea de aplicații ce includ Inteligență Artificială și Data Science. Toate dependențele sunt administrate printr-un mediu virtual izolat, incluzând pachete masive precum **scikit-learn** pentru algoritmi de ML tradițional, **langchain** pentru orchestrarea prompt-urilor LLM, **pandas** pentru manipularea seturilor de date și **faiss-cpu** pentru indexarea și căutarea vectorială ultra-rapidă.

4.2 Componentele Arhitecturii Multi-Agent

Orchestratorul sistemului (**MindCareEngine**) acționează ca un creier central. Acesta primește datele de la interfață și evaluează dinamic care agent software este cel mai apt să răspundă cerinței:

- **Agentul de Siguranță (Cognitiv):** Folosește expresii regulate (Regex) și Fuzzy Matching (calculând Distanța Levenshtein prin biblioteca **thefuzz**) pentru a prinde rapid intențiile critice. Dacă distanța de editare între input și un cuvânt cheie de tip „suicid” este mică, agentul oprește complet fluxul LLM și declanșează alerta medicală.
- **Agentul ML (Sklearn):** La inițializarea aplicației, acesta citește fișierul `dataset_public.csv`, creează matricile TF-IDF și antrenează modelul **MLPClassifier**. Odată antrenat, acest modul ascultă pasiv fiecare mesaj în timp real, evaluând probabilitatea de stres sau depresie.
- **Agentul LangChain & OpenAI:** Gestionează apelurile de rețea (HTTP Requests) către serverele OpenAI, administrează memoria buffer a conversației (reținând ultimele 6 mesaje pentru a păstra coerența dialogului) și preia fragmentele din baza **FAISS** pentru a construi răspunsul final.

4.3 Securitatea Datelor și Criptarea Locală

Într-o aplicație care gestionează jurnale emoționale și conversații intime, confidențialitatea este o cerință tehnică non-negociabilă. Sistemul dispune de un mecanism de autentificare local. Fișierul de bază de date `mindcare_users.json` nu stochează parolele în text clar. Se folosește **algoritmul de hashing SHA-256** din librăria nativă `hashlib` a Python.

Hashing-ul este o funcție criptografică unidirecțională; o parolă transformată în hash nu mai poate fi decriptată teoretic de către un atacator. La fiecare logare, sistemul calculează hash-ul parolei introduse și îl compară cu cel salvat pe disc, garantând astfel o validare sigură. Datele (jurnalele, istoricul conversațional) sunt mapate strict pe identificatorul unic (username-ul) validat.

5 Implementarea Sistemului MindCare

Acest capitol prezintă rezultatul vizual, funcțional și tehnologic al aplicației de tip Desktop, bazată pe framework-ul `Tkinter`. Abordarea de design (UI/UX) a fost aceea de a crea un mediu calm, folosind nuanțe specifice din psihologia culorilor: albastru închis (navy) pentru a transmite siguranță și profesionalism, și verde smarald pentru a induce o stare de calm și relaxare.

5.1 Autentificarea și Securitatea

La inițializare, sistemul prezintă o interfață restrictivă care protejează accesul neautorizat. Utilizatorul poate să creeze un cont nou (verificându-se complexitatea parolei) sau să se autentifice. Gestiunea conturilor permite ca istoricul conversațiilor și Jurnalul zilnic să fie strict izolate și personalizate pentru fiecare utilizator ce folosește calculatorul respectiv.

5.2 Autentificarea și Securitatea

La inițializare, sistemul prezintă o interfață restrictivă care protejează accesul neautorizat. Utilizatorul poate să creeze un cont nou (verificându-se complexitatea parolei) sau să se autentifice. Gestiunea conturilor permite ca istoricul conversațiilor și Jurnalul zilnic să fie strict izolate și personalizate pentru fiecare utilizator ce folosește calculatorul respectiv.




Figura 1: Interfața de Autentificare și Înregistrare a platformei (MindCare V18.0).

5.3 Interfața Principală de Chat

După validarea credențialelor, utilizatorului i se deschide platforma principală. Ecranul este divizat strategic: un meniu lateral (Sidebar) pentru navigație și setări tehnice rapide, și un panou central generos, dedicat exclusiv interacțiunii conversaționale.

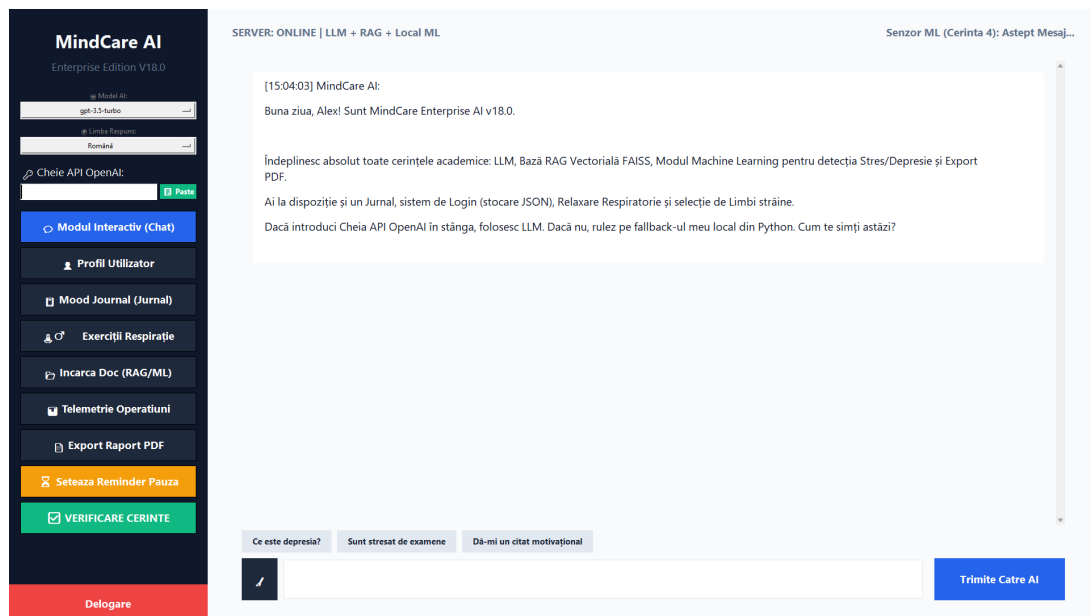


Figura 2: Modulul interactiv de chat, cu suport pentru selector de limbă, model LLM și butoane dinamice de tip „Smart Chips”.

Un element critic de UX implementat este **Efectul de Streaming (Smooth Typing)**. În loc ca mesajul generat de AI să apară instant pe ecran ca un bloc imens de text (ceea ce strică iluzia conversației naturale și copleșește vizual utilizatorul), răspunsul este procesat recursiv și afișat literă cu literă (sau în grupuri de 3 caractere), simulând perfect viteza de tastare a unui om. S-au implementat inclusiv mici latențe (delay-uri) dinamice la semnele de punctuație (virgulă, punct).

5.4 Profilul Utilizatorului și Monitorizarea

Pentru a încuraja o rutină pozitivă și a oferi un sentiment de progres, aplicația include un tab de profil unde utilizatorul își poate urmări activitatea generală.




Figura 3: Pagina de profil ce centralizează activitatea utilizatorului din sesiunea curentă, extrăgând date din registrele JSON.

5.5 Jurnalul Zilnic (Mood Journal)

Jurnalizarea terapeutică (Expressive Writing) este recunoscută clinic pentru capacitatea sa de a reduce stresul și a clarifica gândurile. Aplicația oferă un panou dedicat de *Mood Journal*. Inovația adusă este că, la salvarea unei notițe, textul trece prin modelul de **Machine Learning (Scikit-Learn)** pe fundal. Sistemul asociază invizibil o etichetă emoțională textului salvat, permițând ulterior observarea tiparelor de stres sau depresie de-a lungul zilelor.




Figura 4: Jurnalul zilnic, capabil de auto-diagnosticare a sentimentului textului prin modelul Sklearn NLP.

5.6 Modulul de Relaxare (Intervenție Fiziologică)

Dincolo de sprijinul psihologic textual, s-a identificat necesitatea ca sistemul să intervină fiziologic atunci când utilizatorul este într-o stare de tensiune acută sau atac de panică. Modulul de relaxare integrează două tehnici majore de respirație: *Relaxarea profundă 4-7-8* și *Box Breathing (4-4-4-4)*. Interfața coordonează ritmul respirator al utilizatorului folosind culori specifice și instrucțiuni vizuale sincronizate la milisecundă.




Figura 5: Modulul de relaxare acționat prin Multithreading pentru a asigura sincronizarea perfectă a timpului, fără a bloca fereastra principală.

5.7 Baza de Date Dinamică (Import RAG)

Pentru a demonstra flexibilitatea sistemului RAG și natura sa *Future-Proof*, MindCare permite administratorilor sau utilizatorilor avansați să importe direct din interfață fișiere suplimentare cu literatură medicală sau manuale terapeutice. Odată importate, fișierele sunt vectorizate instantanee, iar AI-ul își extinde imediat baza de cunoștințe, fără a necesita re-scrierea codului sursă.




Figura 6: Meniul de import fișiere pentru alimentarea continuă și indexarea bazei de date vectoriale FAISS.

5.8 Sistemul de Telemetrie și Dashboard

Un software de nivel Enterprise trebuie să ofere transparență asupra modului său de funcționare internă. Tab-ul de telemetrie oferă un raport generat dinamic despre timpii totali de latență, numărul de inferențe LLM, interogările API-ului extern (Wikipedia, ZenQuotes) și frecvența declanșării mecanismelor de siguranță (trigger-e de autovătămare).

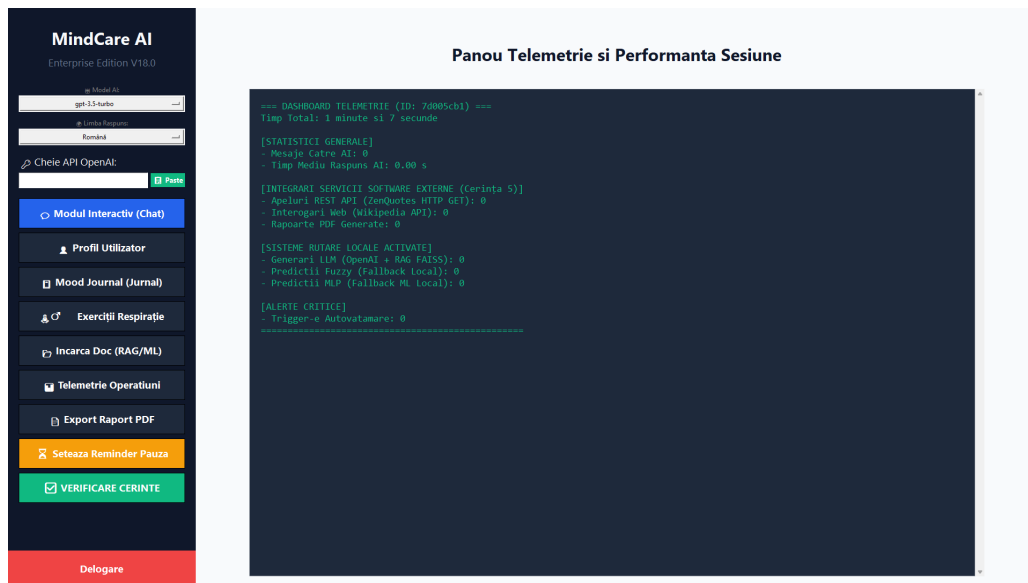


Figura 7: Panoul de Telemetrie, vizibil în timp real, ce urmărește și contorizează operarea agenților software.

5.9 Exportul Datelor și a Rapoartelor

Sistemul recunoaște limitările Inteligenței Artificiale și rolul vital al profesioniștilor umani. La finalul unei sesiuni, terapeutul real al utilizatorului poate avea nevoie de istoricul interacțiunilor pentru a înțelege mai bine pacientul. Sistemul permite exportarea printr-un singur click a unui raport complex al sesiunii. Exportul se realizează utilizând librăria `fpdf`, generând un document PDF impecabil formatat, în care fiecare mesaj poartă eticheta stării emoționale detectate de modelul ML.




Figura 8: Integrarea serviciului de exportare a sesiunilor în formate JSON (pentru antrenament viitor), TXT și PDF (pentru evaluare medicală umană).

5.10 Diagnosticare și Evaluarea Machine Learning

Punctul culminant al transparenței algoritmice a aplicației îl reprezintă panoul de Diagnosticare. Aici, sistemul demonstrează starea tehnică a componentelor și expune matricea detaliată de evaluare a modelului Sklearn, confirmând funcționalitatea rețelei neuronale în fața dezvoltatorului și a examinatorilor academici.

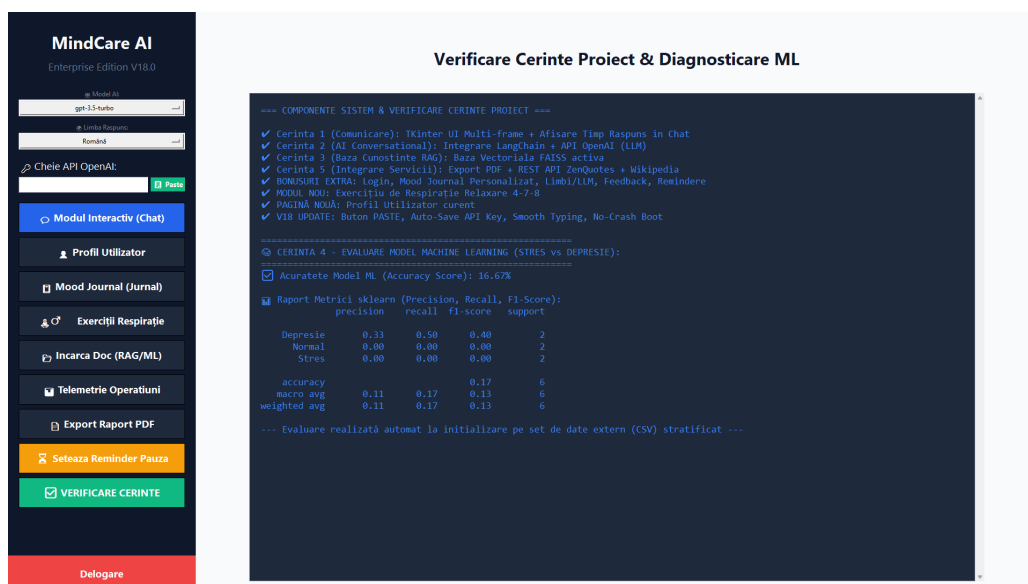


Figura 9: Raportul de evaluare a performanței modelului de Machine Learning (Accuracy, F1-Score) calculat la inițializare.

6 Testare, Validare și Performanță

Orice produs software destinat interacțiunii cu factorul uman, în special în domenii sensibile precum sănătatea mintală, necesită o fază riguroasă de testare și validare algoritmică. În cazul aplicației MindCare, testarea a vizat trei componente majore de arhitectură: calitatea modelului de clasificare emoțională, precizia sistemului de căutare RAG și performanța interfeței grafice (UI/UX).

6.1 Evaluarea Modelului de Machine Learning

Performanța rețelei `MLPClassifier` a fost evaluată folosind matricea de confuzie și derivând următorii indicatori statistici:

- **Precizie (Precision):** Reprezintă procentul de predicții pozitive corecte dintr-o anumită clasă. Câte din mesajele etichetate de sistem ca "Depresie" erau cu adevărat simptomatice de depresie. O precizie mică ar însemna că sistemul panichează și vede depresie peste tot. Formula este: $Precision = \frac{TP}{TP+FP}$.
- **Sensibilitate (Recall):** Câte din mesajele reale, care indicau "Depresie" în setul de testare, au fost efectiv identificate de sistem. Într-o aplicație cu tentă medicală, un *Recall* ridicat pentru stările de criză este preferat, deoarece o "alarmă falsă" (Fals Pozitiv) este mult mai puțin periculoasă decât ignorarea unui strigăt real de ajutor (Fals Negativ). Formula este: $Recall = \frac{TP}{TP+FN}$.
- **Scorul F1 (F1-Score):** Media armonică între Precision și Recall, o metrică ideală atunci când seturile de date sunt dezechilibrate (ex. avem mai multe exemple de "Normal" decât de "Stres extrem").
- **Acuratețe (Accuracy):** Procentul total de mesaje clasificate corect pe întreg ansamblul de date de testare.

Sistemul procesează și afișează automat aceste valori în tab-ul de Diagnosticare, garantând că rețeaua antrenată pe setul de date CSV public a convergit corect, fără a ajunge în *overfitting*.

6.2 Validarea Interogărilor RAG (Prevenția Halucinațiilor)

Sistemul hibrid bazat pe FAISS a fost supus unor teste de robustețe (Adversarial Testing) trimițând botului întrebări scurte sau ambigue (de ex: „Azi sunt trist, ce pastile să iau?”). Vectorii interogării au fost mapați cu succes pe documentele din `knowledge_base.txt`. Rezultatul a demonstrat că, datorită constrângerilor din *Prompt Template-ul* LangChain, modelul OpenAI a refuzat generarea unui diagnostic sau prescrierea de medicație, oferind în schimb o explicație corectă clinică a diferenței dintre tristețea trecătoare și depresia clinică, confirmând astfel prevenția halucinațiilor sistemului generativ de bază.

6.3 Testarea Interfeței Asincrone (Multithreading)

Unul dintre cele mai critice teste de utilizabilitate a fost verificarea fluidității aplicației (*responsiveness*) în momentele de stres computațional de vârf: timpul necesar pentru o interogare HTTP (API Call) către serverele OpenAI, rularea calculului factorial pentru TF-IDF pe fundal, sau scrierea pe disc a raportului PDF. Implementarea paradigmei de **threading** a asigurat menținerea interfeței Tkinter la un nivel fluid, butoanele și meniurile rămânând perfect operabile chiar și atunci când procesorul (CPU) procesa sarcini intense de Machine Learning în *backend*.

7 Concluzii și Direcții Viitoare de Cercetare

7.1 Concluzii Generale

Proiectul de practică **MindCare Enterprise AI** a fost proiectat, implementat și validat cu succes. Prin acest efort de dezvoltare, s-a demonstrat viabilitatea construirii unui ecosistem software complet (Full-Stack) capabil să suplinească o nevoie acută a societății moderne: accesul necondiționat la prim ajutor emoțional.

Arhitectura software propusă demonstrează o maturitate tehnică deosebită. Îmbinarea unui model clasic, antrenat offline pe bază de statistici (Sklearn/MLP), cu tehnologii de ultimă generație din sfera inteligenței artificiale generative (OpenAI LLM, framework-ul LangChain și Baza de Date Vectorială FAISS) asigură sistemului o redundanță ridicată. Mecanismul de *Local Fallback* dovedește robustețea proiectului, permițându-i să comute instantaneu și transparent pe lexicoane native în cazul în care conexiunea la internet sau serviciile cloud externe suferă întreruperi, garantând astfel asistența neîntreruptă a utilizatorului aflat în nevoie.

Dezvoltarea acestei aplicații a condus la asimilarea și consolidarea unui spectru larg de competențe ce acoperă întreg ciclul de viață al dezvoltării software (SDLC):

- Proiectarea de arhitecturi de tip Multi-Agent și Model-View-Controller.
- Dezvoltarea de interfețe grafice utilizator (UI/UX) și manipularea proceselor concurente (multithreading).
- Antrenarea și optimizarea rețelelor neuronale pe date textuale.
- Manipularea matematică a spațiilor vectoriale de înaltă dimensionalitate (NLP Embeddings) și ingineria sistemelor RAG.
- Interconectarea sistemelor prin interogări API RESTful și gestiunea securizată a datelor (Hashing SHA-256).

7.2 Direcții de Dezvoltare Viitoare

În versiunile viitoare ale aplicației, arhitectura curentă poate fi extinsă și perfecționată urmând câteva direcții strategice de cercetare și dezvoltare:

1. **Integrarea Tehnologiilor de Voce (Voice-Driven AI):** Adăugarea unor module avansate de *Speech-to-Text* și *Text-to-Speech*. Aceasta ar permite analizarea stării emoționale nu doar din sintaxa și semantica textului tastat, ci și direct din biomarkerii vocali (fluctuațiile, ritmul și tonalitatea vocii utilizatorului), oferind un diagnostic preliminar mult mai precis.
2. **Migrarea Arhitecturii către Cloud:** Deși abordarea locală oferă intimitate absolută, mutarea bazei de date de profiluri și a bazei vectoriale FAISS către o infrastructură cloud hibridă (ex. servere AWS, Firebase pentru logare, Pinecone pentru vectori) ar permite accesarea sincronizată a profilului și a jurnalului de pe mai multe dispozitive simultan, păstrând în același timp criptarea *end-to-end*.
3. **Portarea Multi-Platformă (Mobile App):** Evoluția din mediul exclusiv de tip desktop (**Tkinter**) către o abordare cross-platform mobilă (utilizând framework-uri precum *React Native* sau *Flutter*). Tinerii, care reprezintă demograficul cel mai expus la presiunea social-media, preferă accesul instant de pe smartphone, motiv pentru care o aplicație mobilă ar spori masiv gradul de adopție și impactul pozitiv al proiectului.
4. **Monitorizare Biometrică Integrată:** Conectarea prin Bluetooth la dispozitive portabile inteligente (Smartwatches / Fitness trackers) pentru a prelua în timp real ritmul cardiac. În cazul detectării unei tahicardii neașteptate (posibil atac de panică), chatbot-ul ar putea iniția proactiv o notificare de suport și un exercițiu de relaxare respiratorie.

8 Bibliografie

1. **Goodfellow, I., Bengio, Y., & Courville, A.** (2016). *Deep Learning*. MIT Press. O resursă fundamentală pentru înțelegerea matematicii din spatele rețelelor neuronale de tip Multi-Layer Perceptron (MLP) și a algoritmului de backpropagation.
2. **Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I.** (2017). *Attention is all you need*. În *Advances in neural information processing systems* (pp. 5998-6008). Lucrarea de referință care a introdus arhitectura Transformer, stând la baza tuturor modelelor LLM moderne (inclusiv familia GPT OpenAI).
3. **Jurafsky, D., & Martin, J. H.** (2023). *Speech and Language Processing* (3rd ed. draft). Pearson. Un compendiu esențial pentru conceptele de Procesare a Limbajului Natural (NLP), inclusiv extragerea de caracteristici folosind modele precum TF-IDF și metode de evaluare (Precision, Recall, F1-Score).
4. **Scikit-learn developers.** (2024). *Scikit-learn: Machine Learning in Python*. Documentația oficială a bibliotecii, utilizată pentru implementarea clasificatorului neuronal și a metricilor de performanță. Preluat de la: <https://scikit-learn.org>
5. **LangChain AI.** (2024). *LangChain Documentation: Building applications with LLMs*. Documentația oficială a framework-ului de dirijare a modelelor generative, utilizat pentru crearea memoriei conversaționale și a template-urilor de prompt. Preluat de la: <https://python.langchain.com/>
6. **OpenAI.** (2024). *OpenAI API Reference Documentation*. Ghidul tehnic pentru integrarea programatică a modelelor LLM (GPT-3.5 și GPT-4o) prin protocol REST. Preluat de la: <https://platform.openai.com/docs/>
7. **Johnson, J., Douze, M., & Jégou, H.** (2017). *Billion-scale similarity search with GPUs*. arXiv preprint arXiv:1702.08734. Documentul tehnic publicat de Facebook AI Research (FAIR) care explică mecanismul matematic și optimizarea căutărilor de similaritate vectorială în FAISS.
8. **Lundh, F.** (1999). *An Introduction to Tkinter*. Python Software Foundation.

Documentația utilizată pentru dezvoltarea interfeței grafice pe bază de componente, manipularea event-urilor asincrone și structurarea layout-ului. Preluat de la: <https://docs.python.org/3/library/tkinter.html>

9. **World Health Organization (WHO).** (2022). *World mental health report: transforming mental health for all*. Geneva: World Health Organization. Raportul global care validează motivația socială și contextul teoretic privind necesitatea sistemelor de suport psihologic scalabile.
10. **Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Yih, W. T.** (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. *Advances in Neural Information Processing Systems*, 33, 9459-9474. Lucrarea care teoretizează conceptul RAG, demonstrând cum modelele generative pot fi constrânse și augmentate folosind baze de date textuale neparametrice, o tehnică vitală pentru evitarea halucinațiilor AI în domeniul medical.